Otimização de Contratações Contextuais em Elencos de Futebol

Lucio Vargas de Albuquerque Nunes

GCC118 – Programação Matemática
2026/2

Introdução

A composição de elencos no futebol profissional constitui um problema de tomada de decisão que envolve a seleção de jogadores sob restrições financeiras, esportivas e estruturais (Pantuso, 2017; Dantas; Ritt, 2025). A escolha de novos atletas depende não apenas de suas características individuais, mas também de sua compatibilidade com os demais integrantes da equipe e de sua contribuição para o desempenho coletivo (Jarvandi; Sarkani; Mazzuchi, 2013). Nesse contexto, técnicas de Pesquisa Operacional permitem identificar combinações de jogadores que maximizem critérios de desempenho, respeitando as restrições estabelecidas.

A integração entre modelos preditivos e técnicas de otimização possibilita avaliar os efeitos estimados das contratações sobre o desempenho de uma equipe. Nessa perspectiva, Nunes (2026) desenvolveu uma metodologia que utiliza estatísticas individuais de jogadores para prever a pontuação de clubes ao longo de uma temporada, empregando essas previsões como função objetivo de algoritmos de otimização. Como continuidade, o presente trabalho propõe investigar uma formulação de Programação Linear Inteira (PLI) baseada em ganhos previamente estimados para possíveis substituições de jogadores, permitindo comparar diferentes métodos de resolução.

Para viabilizar essa abordagem, torna-se necessário avaliar a qualidade, a consistência e a adequação dos dados utilizados na construção das instâncias de otimização. Assim, esta etapa tem como objetivo realizar uma análise exploratória da base histórica da Premier League e da Serie A italiana, previamente estruturada por Nunes (2026) a partir de dados do FBref (FBref, 2026). Serão examinados o tamanho das instâncias, a qualidade dos registros e sua viabilidade diante das restrições posicionais e orçamentárias, fornecendo subsídios para as etapas posteriores de modelagem matemática e desenvolvimento de métodos heurísticos.

Caracterização da Base de Dados

A base de dados utilizada neste trabalho foi construída por Nunes (2026) a partir de estatísticas disponibilizadas pelo FBref (FBref, 2026). A coleta foi realizada por meio de *web scraping* com Python e Beautiful Soup, abrangendo jogadores e resultados de partidas da Premier League inglesa e da Serie A italiana, entre as temporadas de 2019–

2020 e 2023–2024. Os dados foram organizados em arquivos CSV por clube e temporada, disponibilizados publicamente em `https://github.com/LunusMax/epl-seriea-data`.

A análise dos arquivos identificou 7.644 registros de jogadores no período considerado, distribuídos em 225 combinações de equipe e temporada. A comparação com os resultados oficiais das partidas permitiu identificar 200 elencos de referência, correspondentes às 20 equipes participantes de cada competição por temporada, totalizando 6.661 registros. Os 983 registros adicionais, associados a clubes que não disputaram a Serie A nas respectivas temporadas, foram preservados para possível utilização como candidatos à contratação.

Cada registro contém 47 atributos, além da identificação do jogador, incluindo idade, posição, partidas disputadas, minutagem e estatísticas de desempenho ofensivo e defensivo. Entre os indicadores disponíveis destacam-se gols, assistências, gols esperados (*expected goals* – xG), assistências esperadas (*expected assists* – xAG), desarmes e interceptações. A construção dessa estrutura envolveu a integração de tabelas estatísticas e a remoção de atributos considerados irrelevantes para a modelagem (Nunes, 2026).

Na metodologia preditiva original, Nunes (2026) selecionou os 20 jogadores com maior minutagem de cada equipe e aplicou a técnica de Análise de Componentes Principais (*Principal Component Analysis* – PCA), obtendo 20 componentes responsáveis por explicar aproximadamente 97,66% da variância dos dados. Dessa forma, cada elenco foi representado por 400 atributos associados aos jogadores, acrescidos da pontuação da equipe na temporada anterior, totalizando um vetor de 401 atributos. As estatísticas individuais da temporada $t-1$ são utilizadas para estimar o desempenho coletivo na temporada t.

No presente trabalho, os dados serão utilizados para definir os elencos de referência, selecionar candidatos e construir instâncias do problema de otimização. O modelo preditivo previamente desenvolvido permitirá estimar os ganhos associados às possíveis substituições, enquanto uma função sintética de valor de mercado será utilizada para representar os custos de contratação (Nunes, 2026).

1 Análise da Qualidade dos Dados

A qualidade da base foi avaliada a partir de verificações de completude, unicidade e consistência dos atributos. Foram analisados 6.661 registros correspondentes aos 200 elencos de referência, cada um contendo 47 atributos e uma coluna de identificação do jogador. A análise de completude considerou valores nulos e campos vazios, enquanto a identificação de duplicatas utilizou a combinação de liga, temporada, equipe e nome do jogador.

A consistência dos dados foi examinada por meio da validação de atributos numéricos, incluindo a presença de valores negativos, idades inválidas e percentuais fora do intervalo de 0 a 100. Também foram verificadas relações entre atributos, como a quantidade de titularidades em relação às partidas disputadas e a correspondência dos indicadores agregados de gols e assistências (G+A) e de desarmes e interceptações (Tkl+Int) com seus respectivos componentes. Os resultados estão apresentados na Tabela 1.

Nenhuma inconsistência foi identificada nas verificações realizadas, indicando que a base apresenta condições favoráveis para a construção das instâncias de otimização. Os resultados dispensam tratamentos corretivos relacionados aos problemas investigados, embora não eliminem a possibilidade de outras inconsistências não contempladas pelos testes.

Tabela 1: Resultados da análise de qualidade dos dados

Indicador	**Resultado**
Registros analisados	6.661
Colunas originais	48
Valores ausentes	0
Registros duplicados	0
Valores não numéricos	0
Valores negativos	0
Idades inválidas	0
Percentuais fora do intervalo permitido	0
Titularidades superiores às partidas disputadas	0
Inconsistências em G+A	0
Inconsistências em Tkl+Int	0

Fonte: Elaborado pelo autor.

2 Dimensionamento das Instâncias de Otimização

O dimensionamento das instâncias considerou as estatísticas dos jogadores na temporada $t-1$ para a construção dos cenários de contratação da temporada t, seguindo a abordagem temporal de Nunes (2026). Assim, para as temporadas-alvo de 2019–2020 a 2023–2024, foram utilizados os registros históricos de 2018–2019 a 2022–2023, respectivamente. A Tabela 2 apresenta a quantidade de registros e nomes distintos disponíveis em cada período, considerando que um mesmo jogador pode possuir registros em diferentes clubes.

Tabela 2: Dimensionamento inicial do universo de candidatos por temporada

Temporada-alvo	**Registros históricos**	**Nomes distintos**
2019–2020	1.287	1.246
2020–2021	1.382	1.311
2021–2022	1.613	1.545
2022–2023	1.557	1.487
2023–2024	1.529	1.456

Fonte: Elaborado pelo autor.

Como cenário experimental, foi selecionado o Napoli na temporada-alvo de 2021–2022, utilizando os dados históricos de 2020–2021. Dos 32 registros do clube, foram selecionados os 20 jogadores com maior minutagem para compor o elenco de referência. Após a exclusão dos atletas pertencentes ao Napoli e a deduplicação dos candidatos externos por nome, foram identificados 1.513 candidatos potenciais, sendo 528 da Premier League e 985 da Serie A.

Foram construídas 12 instâncias, combinando conjuntos de 20, 50, 100, 200, 500 e 1.000 candidatos com três ou cinco vagas disponíveis. Os candidatos foram ordenados pela minutagem histórica, enquanto as vagas corresponderam aos jogadores de menor minutagem do elenco de referência. A formulação proposta considera variáveis binárias x_{ij}, que representam a atribuição do candidato i à vaga j. O número teórico dessas variáveis corresponde a $n \times m$, sendo n a quantidade de candidatos e m a quantidade de vagas. Entretanto, combinações sem compatibilidade posicional podem ser eliminadas previamente, conforme apresentado na Tabela 3.

Tabela 3: Dimensionamento das variáveis binárias considerando compatibilidade posicional

Candidatos	Vagas	Teóricas	Compatíveis	Redução (%)
20	3	60	12	80,00
20	5	100	26	74,00
50	3	150	33	78,00
50	5	250	71	71,60
100	3	300	91	69,67
100	5	500	157	68,60
200	3	600	212	64,67
200	5	1.000	329	67,10
500	3	1.500	606	59,60
500	5	2.500	871	65,16
1.000	3	3.000	1.297	56,77
1.000	5	5.000	1.776	64,48

Fonte: Elaborado pelo autor.

A filtragem posicional reduziu entre 56,77% e 80,00% a quantidade de pares candidato–vaga admissíveis. Na maior instância, com 1.000 candidatos e cinco vagas, o número de variáveis binárias potenciais passou de 5.000 para 1.776, representando uma redução de 64,48%. Esses resultados permitem estimar o dimensionamento inicial da futura formulação de PLI, mas não constituem uma avaliação de seu desempenho computacional. A viabilidade das instâncias diante das restrições de unicidade e orçamento será examinada na seção seguinte.

3 Análise de Viabilidade das Instâncias

3.1 Viabilidade Posicional

A viabilidade posicional foi avaliada por meio de um algoritmo de emparelhamento máximo em grafo bipartido, no qual candidatos e vagas representam os dois conjuntos de vértices, conectados quando existe compatibilidade entre suas posições. O procedimento permitiu verificar se todas as vagas poderiam ser preenchidas simultaneamente por jogadores distintos.

Todas as 12 instâncias apresentaram emparelhamentos completos, demonstrando sua viabilidade posicional. Entretanto, nas configurações com 20 candidatos, determinadas vagas possuíam apenas uma opção compatível, enquanto, nas instâncias com 1.000 candidatos, o número mínimo de alternativas por vaga alcançou 300 e 72 nos cenários com três e cinco vagas, respectivamente. Embora esses resultados confirmem a possibilidade de preenchimento das vagas, a viabilidade completa também depende das restrições orçamentárias.

3.2 Viabilidade Orçamentária

A viabilidade orçamentária foi analisada utilizando a função de custo sintético proposta por Nunes (2026), baseada na idade e nos indicadores estatísticos dos jogadores. Foram considerados orçamentos de 30, 60 e 120 milhões de unidades monetárias sintéti-

cas. Para cada instância, o custo mínimo necessário ao preenchimento de todas as vagas foi determinado por meio de um algoritmo de atribuição de custo mínimo da biblioteca SciPy, respeitando a compatibilidade posicional e a unicidade dos jogadores.

Os 36 cenários avaliados resultaram em dez configurações viáveis, conforme apresentado na Tabela 4. Apenas duas instâncias foram viáveis com os orçamentos de 30 e 60 milhões, enquanto seis atenderam ao limite de 120 milhões.

Tabela 4: Resultados da análise de viabilidade orçamentária

Orçamento (milhões)	**Instâncias**	**Viáveis**	**Inviáveis**
30	12	2	10
60	12	2	10
120	12	6	6
Total	**36**	**10**	**26**

Fonte: Elaborado pelo autor.

A ampliação do conjunto de candidatos possibilitou identificar combinações de menor custo. Nas instâncias com três vagas, o custo mínimo diminuiu de 148,59 milhões, com 20 candidatos, para 18,37 milhões, com 1.000 candidatos. Para cinco vagas, a redução foi de 234,72 milhões para 29,76 milhões. Esses resultados evidenciam a influência do dimensionamento das instâncias sobre a viabilidade financeira das contratações.

A análise identificou ainda 16 jogadores com custo sintético nulo, todos com idade igual ou superior a 30 anos e sem minutos disputados na temporada de referência. Entretanto, nenhum deles integrou as instâncias experimentais, cujos candidatos apresentaram minutagem positiva. Esse comportamento evidencia uma limitação da função de custo, recomendando-se a adoção explícita de critérios mínimos de participação em aplicações futuras. Ressalta-se que os valores utilizados são sintéticos e não representam necessariamente os preços reais de transferência dos atletas.

Conclusão

A análise exploratória permitiu avaliar a qualidade dos dados e a viabilidade das instâncias propostas para o problema de otimização de contratações de jogadores de futebol. Foram identificados 200 elencos de referência, totalizando 6.661 registros, sem ocorrência de valores ausentes, duplicações ou inconsistências nas verificações realizadas. A aplicação de critérios de compatibilidade posicional reduziu significativamente o número potencial de variáveis binárias, e todas as 12 instâncias experimentais apresentaram viabilidade posicional.

A incorporação das restrições orçamentárias, entretanto, resultou em apenas dez cenários viáveis entre os 36 avaliados, evidenciando a influência dos custos e da quantidade de candidatos sobre a existência de soluções admissíveis. Apesar das limitações associadas à utilização de custos sintéticos, os resultados indicam que a base apresenta condições adequadas para a construção das instâncias de otimização. Como continuidade, serão implementados a formulação de Programação Linear Inteira e os métodos heurísticos, permitindo comparar a qualidade das soluções e o desempenho computacional das diferentes abordagens.

Referências

DANTAS, Guilherme Pettene; RITT, Marcus. Squad Optimizing: Integrating Tactics into Football Team Composition Problem via Integer Programming. **Environment Systems and Decisions**, v. 45, n. 3, p. 1–14, 2025. DOI: 10.1007/s10669-025-10033-2.

FBREF. **FBref: Football Statistics and History**. Disponível em: https://fbref.com/. Acesso em: 3 set. 2026.

JARVANDI, Ali; SARKANI, Shahram; MAZZUCHI, Thomas. Modeling Team Compatibility Factors Using a Semi-Markov Decision Process: A Data-Driven Approach to Player Selection in Soccer. **Journal of Quantitative Analysis in Sports**, v. 9, n. 4, p. 347–366, 2013. DOI: 10.1515/jqas-2012-0054.

NUNES, Lucio Vargas de Albuquerque. **Otimização da Montagem de Elenco no Futebol: Aprendizado de Máquina para Redução da Imprevisibilidade em Contratações**. 2026. Dissertação de Mestrado em Ciência da Computação – Universidade Federal de Lavras, Lavras, MG.

PANTUSO, Giovanni. The Football Team Composition Problem: A Stochastic Programming Approach. **Journal of Quantitative Analysis in Sports**, v. 13, n. 4, p. 179–207, 2017. DOI: 10.1515/jqas-2017-0030.