Otimização de Contratações Contextuais em Elencos de Futebol

Lucio Vargas de Albuquerque Nunes

GCC118 – Programação Matemática
2026/2

Introdução

A composição de elencos no futebol profissional constitui um problema de tomada de decisão que envolve a seleção de jogadores sob restrições financeiras e esportivas (Pantuso, 2017). A escolha de novos atletas não depende exclusivamente de suas características individuais, mas também de sua compatibilidade com os demais integrantes da equipe e de sua contribuição potencial para o desempenho coletivo (Jarvandi; Sarkani; Mazzuchi, 2013). Nesse contexto, técnicas de Pesquisa Operacional têm sido empregadas para representar o problema de composição de elencos, permitindo identificar combinações de jogadores que maximizem determinados critérios de desempenho, respeitando restrições orçamentárias, posicionais e regulatórias (Pantuso, 2017; Dantas; Ritt, 2025).

A integração entre modelos preditivos e técnicas de otimização possibilita avaliar contratações não apenas por indicadores individuais, mas também por seus efeitos estimados sobre o desempenho de uma equipe. Nessa perspectiva, Nunes (2026) desenvolveu uma metodologia que utiliza estatísticas individuais de jogadores para prever a pontuação de clubes ao longo de uma temporada, empregando posteriormente essas previsões como função objetivo de algoritmos de otimização. Como continuidade dessa abordagem, o presente trabalho propõe investigar uma formulação de Programação Linear Inteira (PLI) baseada em ganhos previamente estimados para possíveis substituições de jogadores, permitindo a aplicação e comparação de diferentes métodos de resolução.

A base de dados utilizada é proveniente do FBref, plataforma que disponibiliza estatísticas históricas de jogadores e equipes de futebol (FBref, 2026). Os dados foram coletados e estruturados por Nunes (2026), abrangendo cinco temporadas, de 2019–2020 a 2023–2024, da Premier League inglesa e da Serie A italiana. O conjunto contempla informações sobre a idade dos atletas e suas estatísticas de desempenho por temporada, abrangendo indicadores ofensivos, defensivos e métricas avançadas. Além disso, a metodologia original incorpora uma função sintética de valor de mercado baseada na idade e em indicadores estatísticos dos jogadores, permitindo representar restrições orçamentárias mesmo na ausência de valores reais de transferência para todos os atletas (Nunes, 2026). A consideração de características individuais e de desempenho na estimativa de custos encontra respaldo em estudos sobre os determinantes econômicos das transferências no futebol profissional (Dobson; Gerrard, 1999).

Entretanto, a aplicação de modelos de otimização depende não apenas da disponibilidade dos dados, mas também de sua qualidade, consistência e adequação às variáveis

e restrições do problema. A necessidade de organização, integração e pré-processamento das estatísticas individuais dos jogadores é evidenciada na metodologia desenvolvida por Nunes (2026). No contexto da composição de elencos, aspectos como a quantidade de jogadores elegíveis, a disponibilidade de atributos estatísticos, a definição de candidatos e vagas e a distribuição dos custos de contratação influenciam a construção das instâncias de otimização e a definição de suas restrições (Pantuso, 2017; Dantas; Ritt, 2025). Dessa forma, torna-se necessário caracterizar a base de dados e examinar suas condições de utilização antes da implementação da formulação matemática.

Assim, esta etapa do trabalho tem como objetivo realizar uma análise exploratória dos dados previamente coletados e estruturados por Nunes (2026), contemplando a caracterização da base, a avaliação de sua qualidade e o dimensionamento das instâncias de otimização. Busca-se identificar possíveis limitações, examinar a disponibilidade das informações necessárias e avaliar sua adequação à construção de cenários de contratação sob restrições orçamentárias e estruturais. Os resultados dessa análise servirão de fundamento para as etapas posteriores de formulação matemática, desenvolvimento de métodos heurísticos e comparação experimental das abordagens de resolução.

Caracterização da Base de Dados

A base de dados utilizada neste trabalho foi originalmente construída por Nunes (2026), a partir de informações disponibilizadas pelo FBref, plataforma especializada em estatísticas históricas de jogadores, equipes e competições de futebol (FBref, 2026). A coleta foi realizada por meio de um algoritmo de *web scraping* desenvolvido em Python, utilizando a biblioteca Beautiful Soup para extrair e organizar as informações disponíveis nas páginas da plataforma. O conjunto de dados contempla estatísticas individuais de jogadores e resultados de partidas de duas das principais competições europeias: a Premier League inglesa e a Serie A italiana.

O período analisado compreende cinco temporadas consecutivas, de 2019–2020 a 2023–2024. Segundo Nunes (2026), foram coletados dados referentes a 2.900 jogadores de 30 equipes da Serie A e 2.399 jogadores de 28 equipes da Premier League, totalizando 5.299 registros informados e 58 equipes distintas ao longo do período considerado. Essa abrangência permite analisar atletas pertencentes a diferentes clubes e temporadas, oferecendo um conjunto de candidatos para a construção de cenários de contratação. Ressalta-se que um mesmo jogador pode aparecer em diferentes temporadas ou clubes, de modo que a quantidade de registros não deve ser necessariamente interpretada como o número de atletas únicos disponíveis para seleção.

As informações foram originalmente obtidas a partir de tabelas de estatísticas ofensivas e defensivas disponibilizadas separadamente pelo FBref. Durante a organização da base, essas tabelas foram integradas para reunir os indicadores de cada jogador em uma estrutura unificada. Também foram removidas colunas duplicadas resultantes da integração e atributos considerados irrelevantes para a modelagem proposta. Ao final desse processo, cada registro passou a conter 47 atributos, além da coluna de identificação do jogador, abrangendo informações sobre idade, posição, participação em partidas e indicadores de desempenho esportivo (Nunes, 2026).

Os atributos disponíveis incluem medidas de participação, como partidas disputadas, titularidades e minutos jogados; indicadores ofensivos, como gols, assistências, gols esperados (*expected goals* – xG) e assistências esperadas (*expected assists* – xAG); além de estatísticas defensivas, como desarmes, interceptações, bloqueios e erros que resultaram

em finalizações adversárias. Parte dessas informações também é apresentada em valores normalizados por 90 minutos, permitindo caracterizar a produção estatística dos atletas em relação ao tempo de participação nas partidas (Nunes, 2026).

Os dados consolidados foram armazenados em arquivos no formato CSV, organizados individualmente por clube e temporada. Essa estrutura permite recuperar as estatísticas dos jogadores de uma equipe em determinado período e identificar candidatos pertencentes a outros clubes. Os arquivos foram disponibilizados publicamente no repositório `https://github.com/LunusMax/epl-seriea-data`, possibilitando sua reutilização e a reprodução dos procedimentos de preparação dos dados descritos por Nunes (2026).

Além das estatísticas individuais, a base original contempla informações sobre os resultados das partidas disputadas nas temporadas analisadas. Esses dados foram utilizados para determinar a pontuação acumulada de cada clube, considerando três pontos por vitória e um ponto por empate. Na metodologia preditiva original, as estatísticas individuais referentes à temporada anterior são utilizadas para estimar a pontuação das equipes na temporada subsequente, estabelecendo uma relação temporal entre as características dos jogadores e o desempenho coletivo observado (Nunes, 2026).

Para a representação dos elencos no modelo preditivo, Nunes (2026) selecionou os 20 jogadores com maior minutagem de cada equipe e aplicou a técnica de Análise de Componentes Principais (*Principal Component Analysis* – PCA), reduzindo os 47 atributos originais para 20 componentes principais, responsáveis por explicar aproximadamente 97,66% da variância dos dados. Dessa forma, cada elenco passou a ser representado por 400 atributos associados aos jogadores, acrescidos da pontuação da equipe na temporada anterior, totalizando um vetor de 401 atributos. Essa representação constitui a entrada do modelo de Aprendizado de Máquina utilizado para estimar os efeitos das possíveis alterações na composição dos elencos.

No contexto do presente trabalho, a base será utilizada para identificar equipes de referência, selecionar jogadores candidatos e construir instâncias do problema de otimização de contratações. As informações individuais permitirão caracterizar os atletas e calcular os custos sintéticos de contratação, enquanto o modelo preditivo previamente desenvolvido poderá ser empregado para estimar os ganhos associados às substituições consideradas. A definição efetiva das instâncias dependerá da aplicação de critérios de elegibilidade e da disponibilidade dos atributos necessários, aspectos que serão examinados nas etapas seguintes da análise exploratória.

1 Análise da Qualidade dos Dados

A qualidade dos dados constitui um aspecto fundamental para a construção de instâncias de otimização, uma vez que informações incompletas, inconsistentes ou redundantes podem comprometer a definição dos parâmetros utilizados na formulação matemática. A base empregada neste trabalho passou por procedimentos prévios de integração, organização e pré-processamento, conforme descrito por Nunes (2026). Nesta etapa, foi realizada uma análise complementar para verificar a completude e a unicidade dos registros disponíveis para a construção dos elencos de referência.

1.1 Completude e Unicidade dos Registros

A análise considerou os 6.661 registros de jogadores pertencentes às 200 combinações de equipe e temporada identificadas nas duas competições entre 2019–2020 e 2023–2024.

Cada registro contém 47 atributos, além da coluna de identificação do jogador. A verificação de completude foi realizada por meio da biblioteca Pandas, considerando tanto valores nulos quanto campos contendo apenas strings vazias ou espaços em branco.

Os resultados não identificaram valores ausentes em nenhuma das 48 colunas originais. Adicionalmente, foi realizada uma verificação de duplicidade considerando a combinação de liga, temporada, equipe e nome do jogador. Não foram identificados registros duplicados segundo esse critério. A Tabela 1 apresenta um resumo dos resultados obtidos.

Tabela 1: Resultados da análise de completude e unicidade dos dados

Indicador	**Resultado**
Registros analisados	6.661
Colunas originais	48
Atributos por registro	47
Valores ausentes	0
Atributos com valores ausentes	0
Registros duplicados	0

Fonte: Elaborado pelo autor.

Os resultados indicam que o conjunto de dados analisado apresenta completude integral nos atributos considerados e ausência de duplicações segundo a chave de identificação adotada. Essas características favorecem a utilização da base na construção das instâncias de otimização, reduzindo a necessidade de procedimentos adicionais de imputação de valores ausentes ou remoção de registros duplicados. Entretanto, a ausência desses problemas não garante, isoladamente, a consistência dos valores armazenados, sendo necessária a verificação complementar dos tipos de dados e dos intervalos admissíveis para os atributos estatísticos.

1.2 Consistência dos Atributos

Além da análise de completude e unicidade, foi realizada uma verificação da consistência dos atributos numéricos presentes na base de dados. Foram examinadas a presença de valores não numéricos em campos estatísticos, a ocorrência de valores negativos, a validade das idades registradas e a adequação dos percentuais de sucesso em desarmes ao intervalo de 0 a 100. Também foram avaliadas relações entre atributos, verificando se o número de partidas iniciadas como titular não excedia o total de partidas disputadas e se os indicadores agregados de gols e assistências (G+A) e de desarmes e interceptações (Tkl+Int) correspondiam à soma de seus respectivos componentes.

A análise foi realizada sobre os 6.661 registros pertencentes aos 200 elencos de referência. Nenhuma ocorrência de inconsistência foi identificada nas sete verificações realizadas, conforme apresentado na Tabela 2.

Os resultados indicam que a base apresenta consistência em relação às regras numéricas e estatísticas avaliadas. Em conjunto com a ausência de valores ausentes e registros duplicados identificada anteriormente, essas evidências demonstram que os dados possuem condições favoráveis para a construção das instâncias de otimização, sem necessidade de tratamentos corretivos adicionais para os problemas investigados. Ressalta-se, entretanto, que essas verificações não eliminam a possibilidade de outras inconsistências semânticas ou limitações inerentes à coleta de dados esportivos.

Tabela 2: Resultados da análise de consistência dos atributos

Verificação	Ocorrências
Valores não numéricos	0
Valores negativos	0
Idades inválidas	0
Percentuais fora do intervalo de 0 a 100	0
Titularidades superiores às partidas disputadas	0
Inconsistências em G+A	0
Inconsistências em Tkl+Int	0

Fonte: Elaborado pelo autor.

2 Dimensionamento das Instâncias de Otimização

O dimensionamento das instâncias de otimização foi realizado a partir dos registros históricos de jogadores disponíveis nas duas competições analisadas. Seguindo a metodologia temporal adotada por Nunes (2026), os dados individuais referentes à temporada $t-1$ foram considerados para a construção dos cenários de contratação da temporada t. Essa abordagem permite utilizar informações anteriores ao período de avaliação, preservando a relação temporal entre os dados disponíveis e as decisões de composição dos elencos.

Inicialmente, foi analisada a quantidade de jogadores disponíveis nas temporadas históricas de 2018–2019 a 2022–2023, utilizadas como referência para os cinco períodos de avaliação. A Tabela 3 apresenta a quantidade de registros e de nomes distintos identificados em cada temporada. A distinção entre essas medidas é necessária porque um mesmo atleta pode apresentar registros associados a diferentes clubes, enquanto a identificação por nome não garante, isoladamente, a individualização de todos os jogadores.

Tabela 3: Dimensionamento inicial do universo de candidatos por temporada

Temporada-alvo	Registros históricos	Nomes distintos
2019–2020	1.287	1.246
2020–2021	1.382	1.311
2021–2022	1.613	1.545
2022–2023	1.557	1.487
2023–2024	1.529	1.456

Fonte: Elaborado pelo autor.

Para investigar o dimensionamento das variáveis de decisão, foi selecionado como cenário experimental o Napoli, considerando a temporada-alvo de 2021–2022 e os dados históricos de 2020–2021. O clube apresentou 32 registros de jogadores na temporada de referência, dos quais foram selecionados os 20 atletas com maior minutagem, seguindo o procedimento utilizado por Nunes (2026). Após a exclusão dos jogadores pertencentes ao clube e a deduplicação dos candidatos externos pelo nome, foi obtido um conjunto de 1.513 candidatos potenciais, sendo 528 provenientes da Premier League e 985 da Serie A.

A formulação proposta considera variáveis binárias x_{ij}, que indicam a seleção do candidato i para ocupar a vaga j no elenco. Para uma instância com n candidatos e m vagas, o número máximo de variáveis binárias corresponde a $n \times m$, quando todas as combinações candidato–vaga são admitidas. Entretanto, a consideração de restrições

posicionais permite eliminar antecipadamente combinações incompatíveis, reduzindo a quantidade de variáveis de decisão necessárias.

Para avaliar esse efeito, foram construídas instâncias experimentais com 20, 50, 100, 200, 500 e 1.000 candidatos, considerando cenários com três e cinco vagas disponíveis. Os candidatos foram ordenados pela minutagem histórica, enquanto as vagas corresponderam aos jogadores de menor minutagem entre os 20 integrantes do elenco de referência. A compatibilidade posicional foi estabelecida pela existência de pelo menos uma posição em comum entre o candidato e o jogador a ser substituído. A Tabela 4 apresenta os resultados obtidos.

Tabela 4: Dimensionamento das variáveis binárias considerando compatibilidade posicional

Candidatos	**Vagas**	**Teóricas**	**Compatíveis**	**Redução (%)**
20	3	60	12	80,00
20	5	100	26	74,00
50	3	150	33	78,00
50	5	250	71	71,60
100	3	300	91	69,67
100	5	500	157	68,60
200	3	600	212	64,67
200	5	1.000	329	67,10
500	3	1.500	606	59,60
500	5	2.500	871	65,16
1.000	3	3.000	1.297	56,77
1.000	5	5.000	1.776	64,48

Fonte: Elaborado pelo autor.

Os resultados demonstram que a aplicação do critério de compatibilidade posicional proporcionou reduções expressivas na quantidade de pares candidato–vaga admissíveis. Na maior instância considerada, composta por 1.000 candidatos e cinco vagas, o número de variáveis binárias potenciais foi reduzido de 5.000 para 1.776, correspondendo a uma redução de 64,48%. Nas demais configurações, os percentuais de redução variaram entre 56,77% e 80,00%, evidenciando o impacto da filtragem posicional sobre o dimensionamento inicial do problema.

Cabe destacar que os resultados apresentados representam estimativas do tamanho da formulação a partir dos pares posicionais admissíveis, não constituindo ainda uma avaliação de desempenho computacional de um modelo PLI implementado. Além disso, a existência de candidatos compatíveis não garante necessariamente o preenchimento simultâneo de todas as vagas, especialmente quando são consideradas restrições de unicidade e orçamento. Essas condições serão examinadas na análise de viabilidade das instâncias, permitindo identificar configurações adequadas para os experimentos posteriores com métodos exatos e heurísticos.

3 Análise de Viabilidade das Instâncias

3.1 Viabilidade Posicional

A viabilidade das instâncias propostas foi inicialmente avaliada considerando as restrições de compatibilidade posicional e unicidade na seleção dos jogadores. Para isso, o problema foi representado por meio de um grafo bipartido, no qual um conjunto de vértices corresponde aos candidatos disponíveis e o outro às vagas a serem preenchidas. Uma aresta conecta um candidato a uma vaga quando existe compatibilidade entre suas posições de atuação. A partir dessa representação, foi utilizado um algoritmo de emparelhamento máximo para verificar a possibilidade de preencher simultaneamente todas as vagas com jogadores distintos.

Foram avaliadas as 12 configurações experimentais anteriormente definidas, considerando conjuntos de 20, 50, 100, 200, 500 e 1.000 candidatos, combinados com três e cinco vagas. Os resultados demonstraram que todas as instâncias apresentaram emparelhamentos completos, sendo possível atribuir jogadores distintos a todas as vagas respeitando a compatibilidade posicional estabelecida.

Embora todas as instâncias tenham apresentado viabilidade posicional, observou-se uma diferença na quantidade de alternativas disponíveis para cada vaga. Nas configurações com 20 candidatos, determinadas vagas apresentaram apenas uma opção compatível. Em contrapartida, nas instâncias com 1.000 candidatos, o número mínimo de alternativas por vaga alcançou 300 no cenário com três vagas e 72 no cenário com cinco vagas. Esses resultados indicam que o aumento do conjunto de candidatos amplia as possibilidades de seleção, embora a distribuição das posições entre os jogadores continue influenciando a estrutura das instâncias.

A viabilidade posicional constatada demonstra que os conjuntos de candidatos são suficientes para preencher as vagas consideradas, respeitando as restrições de atribuição individual. Entretanto, essa condição não garante a viabilidade completa do problema de otimização, uma vez que ainda devem ser consideradas as limitações orçamentárias associadas aos custos de contratação. Dessa forma, torna-se necessária uma análise complementar para verificar a existência de combinações de jogadores que atendam simultaneamente às restrições posicionais e financeiras.

Conclusão